

第 2 章 概览 (Overview)



孙秋壮

在进行系统的鲁棒优化学习之前，我们进行一些预备知识的回顾。本章将对线性规划、凸优化、锥优化以及风险偏好及其度量进行简要介绍。

2.1 线性规划概览 (Linear optimization)

线性规划 (LP) 是数学规划中形式最为简单的一种模型。一个线性规划可以写作：

$$\begin{aligned} \min \quad & \mathbf{c}^\top \mathbf{x} \\ \text{s.t.} \quad & \mathbf{A}\mathbf{x} \geq \mathbf{b}, \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

可见上式中，目标函数和约束都是线性的形式，所以被叫做“线性规划”。虽然它的形式简单，但线性规划的建模能力非常强大，有很多经典的数学建模问题都可以转化为线性规划，也有很多非线性的函数也可以等价转化为线性规划求解。比如对于如下非线性的规划

$$\begin{aligned} \min \quad & f(\mathbf{x}) = \max_k \{\mathbf{d}_k^\top \mathbf{x} + c_k\} \\ \text{s.t.} \quad & \mathbf{A}\mathbf{x} \geq \mathbf{b}. \end{aligned}$$

我们可以等价地将其转化为线性规划

$$\begin{aligned} \min \quad & z \\ \text{s.t.} \quad & \mathbf{A}\mathbf{x} \geq \mathbf{b}, \\ & z \geq \mathbf{d}_k^\top \mathbf{x} + c_k \quad \forall k. \end{aligned}$$

当然，在实际解决过程的问题中要十分注意转化是否等价！一个常见的错误就是认为如下的两个数学规划问题是等价的。

$$\begin{array}{ll} \min & \sum_{j \in [N]} c_j |x_j| \\ \text{s.t.} & \mathbf{A}\mathbf{x} \geq \mathbf{b}. \end{array} \quad \begin{array}{ll} \min & \sum_{j \in [N]} c_j z_j \\ \text{s.t.} & \mathbf{A}\mathbf{x} \geq \mathbf{b}, \\ & x_j \geq -z_j, \\ & -x_j \geq -z_j. \end{array}$$

其实，当第一个规划问题有界，且存在 $c_j < 0$ 时，我们可以令线性规划中对应的 $z_j \mapsto +\infty$ ，使得第二个问题最优值趋向于 $-\infty$ 。此时易见两个问题并非等价。

说到数学规划问题，就不得不提到对偶 (duality) 理论。考虑一个（标准形式的）线性规划问题：

$$\begin{aligned} \min \quad & \mathbf{c}^\top \mathbf{x} \\ \text{s.t.} \quad & \mathbf{A}\mathbf{x} = \mathbf{b}, \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

我们可以使用拉格朗日乘子将上述问题写成：

$$\begin{aligned} g(\mathbf{p}) = \min \quad & \mathbf{c}^\top \mathbf{x} + \mathbf{p}^\top (\mathbf{b} - \mathbf{A}\mathbf{x}) \\ \text{s.t.} \quad & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

令 \mathbf{x}^* 为线性规划的最优解，可见

$$g(\mathbf{p}) \leq \mathbf{c}^\top \mathbf{x}^* + \mathbf{p}^\top (\mathbf{b} - \mathbf{A}\mathbf{x}^*) = \mathbf{c}^\top \mathbf{x}^* \quad \forall \mathbf{p}.$$

也就是说， $g(\mathbf{p})$ 是最优目标函数 $\mathbf{c}^\top \mathbf{x}^*$ 的一个下界。为了使这个下界尽可能的“紧”一些，我们想要求得 $\max_{\mathbf{p}} g(\mathbf{p})$ ：

$$g(\mathbf{p}) = \min_{\mathbf{x} \geq \mathbf{0}} \mathbf{c}^\top \mathbf{x} + \mathbf{p}^\top (\mathbf{b} - \mathbf{A}\mathbf{x}) = \mathbf{p}^\top \mathbf{b} + \min_{\mathbf{x} \geq \mathbf{0}} (\mathbf{c} - \mathbf{A}^\top \mathbf{p})^\top \mathbf{x}.$$

其中，我们有

$$\min_{\mathbf{x} \geq \mathbf{0}} (\mathbf{c} - \mathbf{A}^\top \mathbf{p})^\top \mathbf{x} = \begin{cases} 0, & \text{如果 } \mathbf{c}^\top - \mathbf{p}^\top \mathbf{A} \geq \mathbf{0}, \\ -\infty, & \text{否则.} \end{cases}$$

至此，我们推出了原问题 (primal) 的对偶形式

$$\begin{aligned} \max \quad & \mathbf{b}^\top \mathbf{p} \\ \text{s.t.} \quad & \mathbf{A}^\top \mathbf{p} \leq \mathbf{c}. \end{aligned}$$

关于原问题和对偶问题的关系，我们有弱对偶和强对偶两个定理。其中弱对偶表述的是：当 \mathbf{x} 是原问题的可行解且 \mathbf{p} 是对偶问题的可行解时，我们一定有 $\mathbf{b}^\top \mathbf{p} \leq \mathbf{c}^\top \mathbf{x}$ 。也就是说原问题 (min) 的最优目标函数都要比对偶问题 (max) 最优目标函数要大。由此定理可知，如果我们能找到一组可行解 (\mathbf{x}, \mathbf{p}) 使得 $\mathbf{b}^\top \mathbf{p} = \mathbf{c}^\top \mathbf{x}$ ，那么 \mathbf{x} 和 \mathbf{p} 就一定分别是原问题和对偶问题的最优解。值得一提的是，弱对偶对任意数学规划问题都成立。而强对偶表述的是：当线性规划有一个最优解时，那么它的对偶问题也有最优解，且两个问题的最优目标函数值相同。注意这里我们加上了线性规划这一条件。在更一般的凸优化中，我们必须验证 Slater condition 来确认强对偶是否成立。关于线性规划的详细介绍，可以参阅 [Bertsimas and Tsitsiklis \(1997\)](#)。

2.2 凸优化概览 (Convex optimization)

虽然线性规划的建模能力十分强大，现实生活中很多非线性问题依然无法被 LP 解决。这个时候我们需要使用非线性规划 (NLP) 来求出最优解。一个非线性规划可以



写作

$$\begin{aligned} \min \quad & f(\mathbf{x}) \\ \text{s.t.} \quad & g_i(\mathbf{x}) \leq 0 \quad \forall i = 1 \in [m], \\ & h_i(\mathbf{x}) = 0 \quad \forall i \in [l]. \end{aligned}$$

其中, $f(\mathbf{x}) : \mathbb{R}^n \mapsto \mathbb{R}$, $g_i(\mathbf{x}) : \mathbb{R}^n \mapsto \mathbb{R}$ 和 $h_i(\mathbf{x}) : \mathbb{R}^n \mapsto \mathbb{R}$ 是关于 \mathbf{x} 的 (通常连续且可微的) 函数。

在非线性规划问题中, 我们通常关注局部最优点和全局最优点。如果对于可行域中的 \mathbf{x} , 对于任意可行域中的 \mathbf{y} 都有 $f(\mathbf{x}) \leq f(\mathbf{y})$, 那么 \mathbf{x} 就是全局最小。类似的, 如果 $f(\mathbf{x})$ 比它周围的点都要小, 那么 \mathbf{x} 是一个局部最小。(局部最小严格定义是, 存在以 \mathbf{x} 为中心的一个开球, 使得 $f(\mathbf{x})$ 比开球和可行域交集中所有可以取到的函数值都要小。) 对于一个一般的非线性规划问题, 我们通常很难验证一个点是局部最优还是全局最优。而如果一个非线性规划问题是凸优化问题, 这个问题便迎刃而解。具体来说, 一个函数 $f : S \mapsto R$ 如果满足 $f(\lambda \mathbf{x}_1 + (1 - \lambda) \mathbf{x}_2) \leq \lambda f(\mathbf{x}_1) + (1 - \lambda) f(\mathbf{x}_2)$, $\forall \lambda \in [0, 1]$, $\mathbf{x}_1, \mathbf{x}_2 \in S$, 那么这个函数就被称为凸函数。在一个非线性规划问题中, 如果 $f(\mathbf{x})$, $g(\mathbf{x})$ 和 $h(\mathbf{x})$ 都为凸函数, 那么这个 NLP 就是一个凸优化问题。

凸优化中一个重要的定理就是, 如果 \mathbf{x}^* 是 f 的局部最小, 那么 \mathbf{x}^* 也是 f 可行域中的全局最小。这个性质使得很多算法 (例如各种迭代下降算法、内点算法等等) 可以找到凸优化问题的全局最优解。我们也可以应用 KKT 条件来验证一个解是否为凸优化的问题的最优解。凸优化的详细介绍可以参阅 Boyd and Vandenberghe (2004)。然而, 在一个凸优化问题中, 凸函数 f , g 和 h 的形式太过多元化。相比之下, 任意一个线性规划都可以转化为标准形式 (参见第 2.1 节)。这样的标准形式可以大大减少推导鲁棒对等式 (robust counterpart) 时的步骤。那么一个凸优化问题可以转变为“标准形式”吗? 为了达到这个目的, 我们将在下节中介绍锥优化。

2.3 锥优化概览 (Conic optimization)

沿用上节的符号系统, 我们考虑目标函数 $f(\mathbf{x})$ 为线性形式的凸优化问题, 即 $f(\mathbf{x}) = \mathbf{c}^\top \mathbf{x}$ 。无论 $g(\mathbf{x})$ 和 $h(\mathbf{x})$ 形式如何, 凸优化问题的可行域一定是一个凸集, 写作 \mathcal{X} 。那么我们考虑的凸优化问题可以表示为:

$$\begin{aligned} \min \quad & \mathbf{c}^\top \mathbf{x} \\ \text{s.t.} \quad & \mathbf{x} \in \mathcal{X}. \end{aligned}$$

这个问题可以等价为如下规划问题

$$\begin{aligned} \min \quad & \mathbf{c}^\top \mathbf{x} \\ \text{s.t.} \quad & y = 1, \\ & (\mathbf{x}, y) \in \mathcal{K}. \end{aligned}$$



其中, $\mathcal{K} = \text{cl}\{(x, y) : x/y \in X, y > 0\}$, $\text{cl}\{\cdot\}$ 表示一个集合的闭包。之所以写成这种形式, 是因为 \mathcal{K} 是一种叫作“锥”的性质非常好的集合。我们把一个集合 \mathcal{K} 叫作锥, 如果对任意的 $x \in \mathcal{K}$, $\lambda x \in \mathcal{K}$ 对所有 $\lambda \geq 0$ 都成立。

基于这个变换, 第一个问题: 如何把线性规划和锥联系起来? 第二个问题是: 如果有办法联系起来, 我们可以把线性规划的优良性质借鉴过来吗? 我们先解决第一个问题——显然, 非负 m 维实数域 \mathbb{R}_+^m 是一个锥。那么, 我们可以把一个线性约束等价为

$$Ax \geq b \Leftrightarrow Ax - b \geq 0 \Leftrightarrow Ax - b \in \mathcal{K}, \quad \mathcal{K} = \mathbb{R}_+^m.$$

而线性规划中很多非常好的数学性质来源于不等号“ \geq ”。具体来说, 不等号满足

- 反射性 (reflexivity): $a \geq a$;
- 反对称性 (antisymmetry): 如果 $a \geq b$ 且 $b \geq a$, 那么 $a = b$;
- 传递性 (transitivity): 如果 $a \geq b$ 且 $b \geq c$, 那么 $a \geq c$;
- 如果 $a \geq b$, 那么 $\lambda a \geq \lambda b$ 对于所有 $\lambda \geq 0$ 成立;
- 如果 $a \geq b$ 且 $c \geq d$, 那么 $a + c \geq b + d$ 。

基于这个观察, 我们是否可以对于一个任意的锥 \mathcal{K} , 定义一个广义的不等式呢? 答案是可以的。我们用“ $\geq_{\mathcal{K}}$ ”来定义如下的广义不等式关系:

$$Ax \geq_{\mathcal{K}} b \Leftrightarrow Ax - b \geq_{\mathcal{K}} 0 \Leftrightarrow Ax - b \in \mathcal{K},$$

$$Ax >_{\mathcal{K}} b \Leftrightarrow Ax - b >_{\mathcal{K}} 0 \Leftrightarrow Ax - b \in \text{int}\mathcal{K},$$

其中, $\text{int}\mathcal{K}$ 表示 \mathcal{K} 的内部 (interior)。可以证明, 不等关系“ $\geq_{\mathcal{K}}$ ”同样继承了不等号“ \geq ”的上述所有性质。基于这个推导, 我们可以将一个(目标函数为线性函数)凸优化问题一般化为锥优化框架

$$\begin{aligned} \min \quad & \mathbf{c}^\top \mathbf{x} \\ \text{s.t.} \quad & A\mathbf{x} = \mathbf{b}, \\ & \mathbf{x} \geq_{\mathcal{K}} 0. \end{aligned}$$

这个形式可以比作锥优化的“标准形式”。可见它和线性规划的标准形式有诸多相似之处。推导到这里, 几个很自然的问题就是, 这个问题的对偶形式是什么样的? 强对偶在这个问题中成立吗? 为了回答这些问题, 首先引入对偶锥的概念。对于锥 \mathcal{K} , 它的对偶锥定义为

$$\mathcal{K}^* = \{\mathbf{y} : \mathbf{y}^\top \mathbf{x} \geq 0, \quad \forall \mathbf{x} \in \mathcal{K}\}.$$

有了这个定义, 我们来推导锥优化的对偶问题。为了简单起见, 我们忽略线性约束, 考虑

$$\begin{aligned} \min \quad & \mathbf{c}^\top \mathbf{x} \\ \text{s.t.} \quad & A\mathbf{x} \geq_{\mathcal{K}} \mathbf{b} \end{aligned}$$

的对偶问题。注意到, 对任意的 $\mathbf{x} \geq_{\mathcal{K}} \mathbf{0}$ 和 $\mathbf{y} \geq_{\mathcal{K}^*} \mathbf{0}$, 我们有 $\mathbf{x}^\top \mathbf{y} \geq 0$ 。我们然后便可以引入拉格朗日乘子使问题等价于

$$\min_{\mathbf{x}} \max_{\mathbf{y} \in \mathcal{K}^*} \mathbf{c}^\top \mathbf{x} + \mathbf{y}^\top (\mathbf{b} - A\mathbf{x}).$$



则对偶函数为

$$\min_{\mathbf{x}} \mathbf{c}^\top \mathbf{x} + \mathbf{y}^\top (\mathbf{b} - \mathbf{A}\mathbf{x}) = \begin{cases} \mathbf{b}^\top \mathbf{y}, & \text{如果 } \mathbf{A}^\top \mathbf{y} = \mathbf{c}, \\ -\infty, & \text{否则.} \end{cases}$$

在 $\mathbf{y} \in \mathcal{K}^*$ 中最大化对偶函数，我们可以得到对偶问题

$$\begin{aligned} \max \quad & \mathbf{b}^\top \mathbf{y} \\ \text{s.t.} \quad & \mathbf{A}^\top \mathbf{y} = \mathbf{c}, \\ & \mathbf{y} \geq_{\mathcal{K}^*} \mathbf{0}. \end{aligned}$$

完成了对偶问题的推导，我们需要回答强对偶在这个问题中是否成立。简单来说，我们有如下结论。对于上述锥优化的“标准型”的原问题和对偶问题：

- 对偶问题的对偶问题等价于原问题。
- 对原问题可行的任意 \mathbf{x} 以及对对偶问题可行的任意 \mathbf{y} ，我们有 $\mathbf{c}^\top \mathbf{x} \geq \mathbf{b}^\top \mathbf{y}$ 。
- 如果原问题有下界，且对某些 \mathbf{x} 有 $\mathbf{Ax} - \mathbf{b} \in \text{int}\mathcal{K}$ 严格成立，那么对偶问题可解，且原问题和对偶问题最优目标函数值相等。
- 如果原问题或对偶问题有界且严格可行 ($\mathbf{Ax} - \mathbf{b} \in \text{int}\mathcal{K}$)， (\mathbf{x}, \mathbf{y}) 是最优解与下列任意一条件等价：(i) $\mathbf{c}^\top \mathbf{x} = \mathbf{b}^\top \mathbf{y}$ ；或 (ii) $\mathbf{y}^\top (\mathbf{Ax} - \mathbf{b}) = 0$ 。

2.4 风险偏好及度量 (Risk preferences and risk measures)

本节主要介绍关于风险度量的基本知识。现实中，我们来决策做一件事（比如投资）时，在未来得到的回报往往都是不确定的。为了衡量一件事未来的风险和收益，人们引入了风险度量的概念。一件事的收益可以用随机变量来表示。同时，我们令 \mathcal{V} 为所有随机变量构成的空间，则其风险度量 (risk measure) μ 需要满足两个特性：

- 单调性：对于任意的 $\tilde{r}, \tilde{s} \in \mathcal{V}$ 且 $\tilde{r} \geq \tilde{s}$ ，那么 $\mu[\tilde{r}] \leq \mu[\tilde{s}]$ 。这里， $\tilde{r} \geq \tilde{s}$ 表示的是 state-wise dominance。
- 平移不变性：对于所有的 $c \in \mathbb{R}$ ， $\mu[\tilde{r} + c] \leq \mu[\tilde{r}] - c$ 。

直观来说，单调性表示的意义为：当一件事未来的收益在任何可能性下都高于另一件事，那么它的风险一定是较小的。同时，平移不变性意味着：当一个资产确定性地增加了一定的价值，那么它的风险就会相应减少相同的数值。

基于上述定义，人们定义了非常多的风险度量。其中一个非常著名的风险度量就是在险价值 (Value-at-Risk, VaR)。VaR 的数学定义如下：

$$\text{VaR}_\alpha[\tilde{r}] := \inf \{m \in \mathbb{R} \mid \mathbb{P}[\tilde{r} + m \geq 0] \geq 1 - \alpha\}.$$

根据上述定义，VaR 衡量了在给定概率 α 下，一份投资可能的损失。例如，一个公司每个月在 $\alpha = 5\%$ 的 VaR 为一亿元。这意味着公司每个月都有 5% 的可能性损失超过一亿元。或者说，一个一亿元的损失平均每 20 个月就要发生一次。根据定义，我们



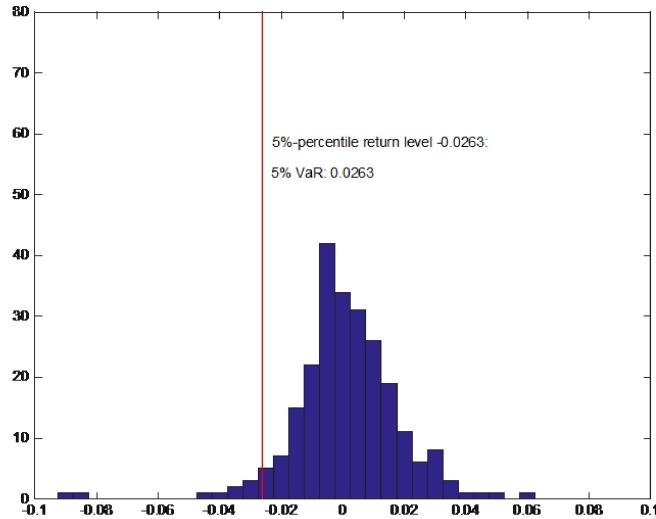


图 2.1: VaR 示例 (from lecture slides of Melvyn Sim)。

同时可以将 VaR 和表示受益的随机变量 \tilde{r} 的分位数联系起来。下图显示，当一个随机变量 5% 的分位数为 -0.0263 时，对应的 VaR 的数值便为 0.0263 。

从上图同样能看出，VaR 的取值只和单独的分位点值相关。而这样的性质会带来一些不便，比如对于有 VaR 介入的优化问题，通常来说都很难求解。同时，VaR 在某些场合不能很好反应出不同投资的风险。假设我们有两种投资策略，其收益分别如下：

- 资产 1：0.95 概率收益 200 万，0.03 概率损失 100 万，0.02 概率损失 200 万；
- 资产 2：0.95 概率收益 200 万，0.03 概率损失 100 万，0.02 概率损失 1000 万。

显而易见资产 2 的风险比资产 1 更大，然而上述两个投资组合的 VaR 都是 100 万。为了解决这个问题，人们又提出了条件风险价值 (Conditional Value-at-Risk, CVaR) 的概念。CVaR 计算了超过 VaR 值的可能损失的期望值，也就是说对于 $\tilde{r} \sim \mathbb{P}$ ，

$$\text{CVaR}_\alpha^*[\tilde{r}] \triangleq \mathbb{E}_{\mathbb{P}}[-\tilde{r} \mid -\tilde{r} \geq \text{VaR}_\alpha(\tilde{r})].$$

这里我们使用 CVaR^* 来表示 CVaR，因为我们在后文中将推导出 CVaR 更常用的一个定义。为了区分，我们加上了一个星号上标。上述这个定义使得 CVaR 对于收益/损失的尾部分布的形状更加敏感。我们根据这个定义也可以看出 $\text{CVaR}_\alpha^*[\tilde{r}] \geq \text{VaR}_\alpha(\tilde{r})$ 。下图显示了 CVaR 和 VaR 的联系。我们也可以计算出在之前例子中，资产 1 的 CVaR 为 140 万，而资产 2 的 CVaR 为 460 万。

现在我们假设一项投资其未来的收益只能取 T 个可能的值 r_1, \dots, r_T 。如果我们取 α 使得 αT 刚好为整数，那么 CVaR 可以等价地表达为

$$\text{CVaR}_\alpha^*[\tilde{r}] = \frac{1}{\alpha T} \max_{\mathcal{S}: |\mathcal{S}| \leq [T], |\mathcal{S}| = \alpha T} \sum_{t \in \mathcal{S}} -r_t.$$

但是这个定义并不通用，因为它不能定义当 αT 不是整数的情况。为此，我们将推导



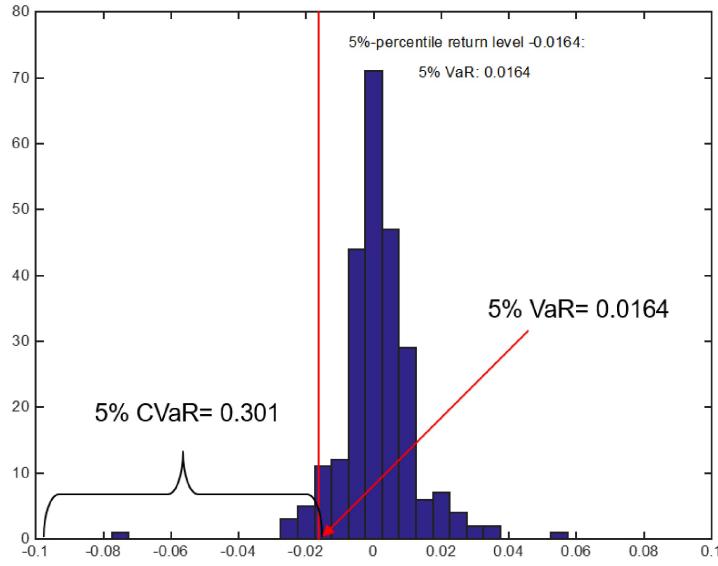


图 2.2: CVaR 示例 (from lecture slides of Melvyn Sim)。

出 CVaR 更通用的一个定义。注意到上式可等价地推出：

$$\begin{aligned} \text{CVaR}_\alpha^*[\tilde{r}] &= \frac{1}{\alpha T} \max_{\substack{\mathcal{S}: \mathcal{S} \subseteq [T], \\ |\mathcal{S}|=\alpha T}} \sum_{t \in \mathcal{S}} -r_t \\ &= \frac{1}{\alpha T} \max_{\substack{z \in \{0,1\}^T \\ z^\top \mathbf{1} = \alpha T}} \sum_{t \in [T]} -r_t z_t \\ &= \frac{1}{\alpha T} \max_{\substack{z \in [0,1]^T \\ z^\top \mathbf{1} = \alpha T}} \sum_{t \in [T]} -r_t z_t. \end{aligned}$$

我们求出上述问题的对偶问题，得到

$$\begin{aligned} \text{CVaR}_\alpha[\tilde{r}] &= \min s + \frac{1}{\alpha T} \mathbf{1}^\top \mathbf{p} \\ \text{s.t. } &s \mathbf{1} + \mathbf{p} \geq -\mathbf{r}, \\ &\mathbf{p} \geq 0, \end{aligned}$$

即

$$\text{CVaR}_\alpha[\tilde{r}] = \inf_s \left\{ s + \frac{1}{\alpha T} \sum_{t \in [T]} (-r_t - s)^+ \right\}.$$

至此，当 αT 不为整数时，我们可以根据上述推导定义 CVaR 为

$$\text{CVaR}_\alpha[\tilde{r}] \triangleq \inf_v \left\{ v + \frac{1}{\alpha} \mathbb{E}_{\mathbb{P}} [(-\tilde{r} - v)^+] \right\}. \quad (2.1)$$

这也是在优化领域中更常用的关于 CVaR 的定义。可以证明，在这个定义下依然有 $\text{CVaR}_\alpha[\tilde{r}] \geq \text{VaR}_\alpha[\tilde{r}]$ 。

我们接下来介绍最优化确定等价收益 (Optimized Certainty Equivalent, OCE)。对于不确定的收益 \tilde{r} ，定义其 OCE 为 (Ben-Tal and Teboulle, 2007)

$$S_u(\tilde{r}) = \sup_{\eta \in \mathbb{R}} \{ \eta + \mathbb{E}_{\mathbb{P}}[u(\tilde{r} - \eta)] \}.$$



其中, $u : \mathbb{R} \mapsto \mathbb{R}$ 为非递减且凹的效用函数, 并满足 $u(0) = 0$, 且 1 是 $u(r)$ 在 $r = 0$ 时的次梯度 (subgradient)。我们可以通过公式这样解释 OCE: 一个决策者希望在未来有 \tilde{r} 的回报, 而且在现在可以消费部分 \tilde{r} 。如果他在现在消费了确定的 η 的价值, 那么 \tilde{r} 的现值就是 $\eta + \mathbb{E}_{\mathbb{P}}[u(\tilde{r} - \eta)]$ 。对 \tilde{r} 进行现在和未来的最优分配, 我们即可得到 OCE。我们可以通过 OCE 来定义对应的风险度量。根据 Ben-Tal and Teboulle (2007), $\mu^{OCE}[\tilde{r}] = -S_u(\tilde{r})$ 是一个一致性风险度量 (coherent risk measure)。为了把问题放进凸优化框架, 我们记 $v = -\eta$, $U(x) = -u(-x)$ 。此时 $U : \mathbb{R} \mapsto \mathbb{R}$ 可以看做一个非递减的凸效用函数, 而对应的风险度量表示为

$$\mu^{OCE}[\tilde{r}] = \inf_{v \in \mathbb{R}} \left\{ v + \mathbb{E}_{\mathbb{P}} [U(-\tilde{r} - v)] \right\}.$$

对比式(2.1), 我们可以看出 CVaR 是一种特殊的 OCE 度量, 满足 $U(r) = r^+/\alpha$ 。

在鲁棒优化领域, 未来收益 \tilde{r} 的分布 \mathbb{P} 往往是不确定的。如果假设分布 \mathbb{P} 处于一个模糊集 (ambiguity set) \mathcal{F} 中, 那么我们就可以写出在最坏情境 (worst case) 下对应的风险度量。以 OCE 举例, 它在最坏情况下的风险度量写作

$$\mu^{OCE}[\tilde{r}] = \inf_{v \in \mathbb{R}} \left\{ v + \sup_{\mathbb{P} \in \mathcal{F}} \mathbb{E}_{\mathbb{P}} [U(-\tilde{r} - v)] \right\}.$$

这样决策优化问题就变成了一个分布鲁棒优化问题。关于分布鲁棒优化问题的求解, 具体可以参见第4章。

我们最后介绍凸风险度量 (convex risk measure)。对于一个风险度量 μ , 它是凸风险度量当且仅当对于任意的 $\tilde{r}, \tilde{s} \in \mathcal{V}$, 有

$$\mu(\lambda \tilde{r} + (1 - \lambda) \tilde{s}) \leq \lambda \mu(\tilde{r}) + (1 - \lambda) \mu(\tilde{s}).$$

值得一提的是, OCE (包括 CVaR) 都是凸风险度量。而且, CVaR 是所有凸风险度量中对 VaR 有最紧上界的一个, 即如果 $\mu[\tilde{r}] \geq \text{VaR}_\alpha[\tilde{r}], \forall \tilde{r} \in \mathcal{V}$, 那么有 $\mu[\tilde{r}] \geq \text{CVaR}_\alpha[\tilde{r}] \geq \text{VaR}_\alpha[\tilde{r}], \forall \tilde{r} \in \mathcal{V}$ 。另一个著名的凸风险度量是 shortfall risk measure (Föllmer and Schied, 2002)。由于篇幅所限不在此展开。有关于风险度量系统的知识, 感兴趣的读者可以参阅 Artzner et al. (1999) 和 Föllmer and Schied (2002)。



本章参考文献

- Artzner, Philippe, Freddy Delbaen, Jean-Marc Eber, and David Heath**, “Coherent measures of risk,” *Mathematical Finance*, 1999, 9 (3), 203–228.
- Ben-Tal, Aharon and Marc Teboulle**, “An old-new concept of convex risk measures: the optimized certainty equivalent,” *Mathematical Finance*, 2007, 17 (3), 449–476.
- Bertsimas, Dimitris and John N Tsitsiklis**, *Introduction to Linear Optimization*, Athena Scientific Belmont, MA, 1997.
- Boyd, Stephen and Lieven Vandenberghe**, *Convex Optimization*, Cambridge university press, 2004.
- Föllmer, Hans and Alexander Schied**, “Convex measures of risk and trading constraints,” *Finance and Stochastics*, 2002, 6 (4), 429–447.